PS PL NPU 协同的
雷达频谱目标识别系统

摘要

面向雷达目标频谱的嵌入式分类，构建 PC 开发与上位机、FMQL30TAI 处理平台及串口屏协同工作的识别系统。以雷达目标识别 LSS-HSR-L 公开数据集为基础，将连续 10 帧、每帧 512 频点组成单通道样本，完成训练策略筛选、三种残差网络对照、代表性窗口校准和 INT8 量化，最终选择 ResNet18 网络模型。板端由 PS 管理文件接收、窗口提取与任务状态，PL 完成输入缓存、搬运及写后读回核对，NPU 执行分类；PS 在输入有效和输出就绪条件满足后发布结果，分别用于 PC 归档及 UART 显示。

独立模型评价中，ResNet18 在固定 250 段测试数据上的板端整段准确率为 92.00%，与 ResNet34 相同；已加载模型的 Icraft SDK 请求平均耗时为 3.0841 ms/10 帧窗口，较 ResNet34 的 5.0372ms/10 帧窗口降低了 38.77%。最终工程已接通 PC、PS/PL/NPU 及实体串口屏，完成单窗预测、结果回传与实屏显示联调。整段精度用于评价模型，现场界面展示用户所选窗口的类别与最高 softmax 概率，工程日志记录该任务各阶段耗时。系统使用公开数据文件回放，配套航迹仅供 PC 查看。

第一部分　作品概述

1.1 功能与特性

LSS-HSR-L 数据集采集到的目标涵盖多种类型，按类别可分为四类：第一类是旋翼无人机，包括大疆 Air3（UAV1）、大疆 Mini3 Pro（UVA2）、大疆 Mavic 3e（UAV3）和大疆 Phantom 4 RTK（UAV4）；第二类是生物目标，包括雀类小型鸟（Bird）、鸟群（Birds）和大型迁徙鸟（Wing Bird）；第三类是地面固定目标，包括地面固定旋转目标（Rotate）；第四类是移动车辆目标，即汽车（Car）[1]。系统识别上述九类目标频谱。PC 上传文件并指定起始帧，板端提取连续 10

帧完成一次分类，回传结果并更新串口屏。输入、输出、模型信息及阶段耗时通过任务标识关联，支持结果归档与历史查看。模型评价阶段另对完整 MAT 的全部合法窗口进行概率聚合，得到整段判决。

1.2 应用领域

系统适用于雷达频谱目标分类、嵌入式模型部署验证及软硬件协同展示。输入为已提取并与目标序列关联的频谱，设计重点是频谱分类模型及其板端执行通路。ADC 采集、FFT、检测和目标序列生成由外部前端提供，后续可按现有接口接入连续频谱数据，完成雷达目标识别的后端处理任务。

1.3 主要技术特点

模型侧通过十帧时间上下文、三级均衡随机采样和代表性校准输入，兼顾分类精度与部署开销。工程侧将普通接收内存、UDMA 源缓冲和 NPU 输入缓冲分开管理，以 PL 写后读回与 PS 整窗比较确认输入，再等待最终输出就绪。任务标识连接网络传输、预测、性能日志和显示历史，使每条结果能够回溯到实际处理的窗口。

1.4 主要性能指标

表 1　核心性能及适用口径

指标	结果	适用范围
整段准确率	92.00%	独立模型测试，230/250 段
SDK 请求均值	3.0841 ms	独立测速，每 10 帧窗口
输入搬运基线均值	1.155 ms	原版通路 1080 窗，含读回
进程 RSS 采样最大	70.88 MiB	独立推理进程，含 SDK

1.5 主要创新点

（1）按精度、时延与内存联合选择适合板端的频谱分类模型。

（2）以 PL 写后读回和 PS 整窗核验约束模型输入，完成可检查的数据交接。

（3）将任务标识贯穿输入、预测、阶段计时和历史显示，支持结果追溯。

1.6 设计流程

从十帧频谱样本和评价规则出发，固定骨干网络筛选训练策略，再比较 ResNet18、ResNet34、ResNet50 并完成量化与硬件测量。确定 ResNet18 后冻结输入输出约定，将其接入 PS/PL 通路，最后用任务事件、原始输出与实时串口屏记录检查系统执行结果。

第二部分　系统组成及功能说明

2.1 系统整体结构

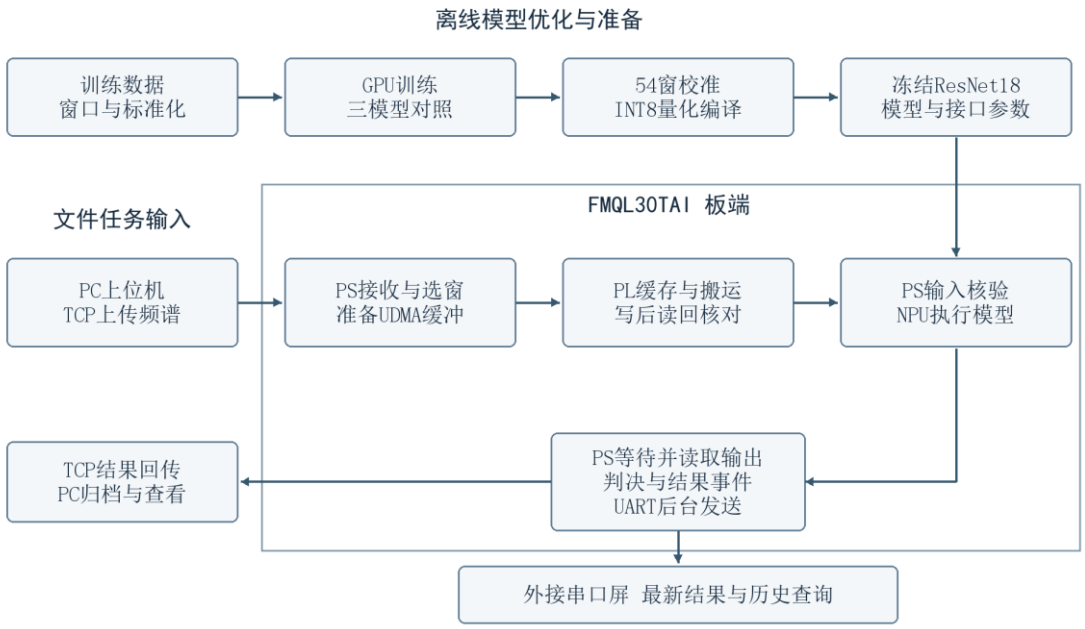


图 1　离线模型优化与板端处理的整体结构

系统包含离线模型准备和板端任务执行两个阶段。离线阶段在 PC 上使用 GPU（RTX 5060 8GB）训练与筛选模型，再用 Icraft 完成量化，交付训练权重、标准化参数及参考样例；执行阶段由 PC 上传频谱文件，PS 选取窗口并调度 PL 搬运，NPU 计算后由 PS 读取、解释和发布结果。PC 保存任务档案，串口屏展示当前预测及历史记录。二者共用模型和窗口定义，分别服务于结果查看与独立显示。

表 2　各模块的功能与交接对象

组成	主要功能	交接对象
PC 模型开发	训练调优、量化、精度及资源比较	冻结训练模型、标准化参数 μ/σ、类别映射与参考输出
PC 上位机	文件任务、TCP 收发、结果归档、轨迹查看	频谱文件、任务参数、结果消息
PS 处理系统	接收校验、选窗、缓冲及状态管理、模型调用	控制参数、输入有效状态、分类结果
PL 可编程逻辑	窗口缓存、数据组块、写入及读回核对	UDMA 源缓冲与 NPU 输入缓冲
NPU 与模型运行时	加载模型、执行计算、提供输入输出访问	10×512 输入与 9 类 logits
UART 显示模块	后台收发、页面更新、历史保存与查询	带任务标识的有效结果事件

2.2 硬件系统

2.2.1 平台组成与连接

硬件以 FMQL30TAI 开发平台为核心。PS 运行 Linux 和常驻 C++服务，负责通信、缓冲和任务调度；PL 实现自定义缓存与搬运逻辑；ZG330 NPU 执行神经网络。PC 与 PS 通过以太网交换文件和结果，USB HOST 经串口转换模块连接 TJC 屏。PL 在本设计中解决 PS 数据到 NPU 输入区域的受控交接问题，与 NPU 的网络计算分工明确。

2.2.2 机械布置与供电连接

系统采用开发板、转换模块和串口屏的桌面集成结构，无独立机械运动机构。布置时保留供电、网口和 USB 接口的插拔空间，并固定线缆。屏幕独立供电，与串口转换模块共地；TX 与 RX 交叉连接，由板端程序管理实际串口设备。现有实物连接见第三部分。

2.2.3 PS 与 PL 之间的数据搬运

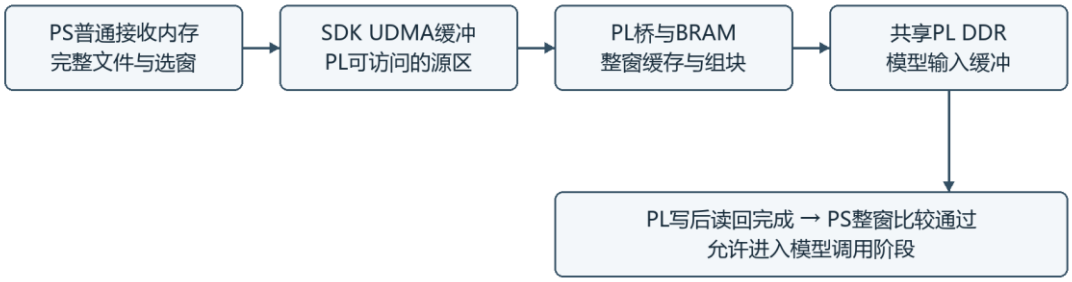


图 2　普通接收内存到 NPU 输入缓冲的数据通路

完整文件先进入 PS 普通接收内存，选定的 10 帧窗口再复制到 SDK 分配的 UDMA 缓冲。UDMA 缓冲用于提供 PL 可访问的源数据，普通内存地址不能直接替代其地址。NPU 输入目标地址由 Icraft SDK 实际绑定；PS 通过桥控制接口配置源地址、目标地址及搬运参数，再启动 PL。

PL 经 BRAM 缓存与数据组块，将窗口写入共享 PL DDR 中的模型输入缓冲，并以写后读回及状态反馈确认搬运完成。PS 随后独立读取目标区域，与原始 20480 字节窗口逐字节比较。只有两级检查通过，才调用模型。当前自定义 PL 逻辑承担输入搬运和完整性检查，FFT 由数据前端完成，分类网络由 NPU 执行。

2.3 数据组织与识别模型设计

2.3.1 识别任务与网络选择依据

LSS-HSR-L 数据集提供已提取并与目标序列关联的多普勒频谱[1]。一个 MAT 对应一段目标序列，频谱为 T×512 矩阵，T 为帧数，每行包含一帧的 512 个多普勒频点；配套 T×5 航迹只用于 PC 查看。九类标签顺序固定为 UAV1、UAV2、UAV3、UAV4、Bird、Birds、Wing Bird、Rotate、Car，索引为 0 至 8。

输入已对应一个目标，任务是判断类别，没有边界框定位输出，因此采用分类网络。二维卷积可处理时间与多普勒两个维度，残差连接为网络训练提供成熟基础[2]；YOLO 的典型形式同时预测位置和类别[5]，与当前输出需求不同。选取

同系列的 ResNet18、ResNet34 和 ResNet50，比较不同网络规模的精度与部署开销。

2.3.2 窗口定义与集合划分

一个模型样本由同一 MAT 中的连续 10 帧组成，大小为 10×512，称为窗口，并继承该 MAT 的类别标签。例如，20 帧 MAT 中的第 1 至 10 帧与第 6 至 15 帧分别形成一个样本。模型一次接收一个窗口，输出 9 个未经 softmax 的类别分数 logits；10 对应时间维，输入通道数为 1。

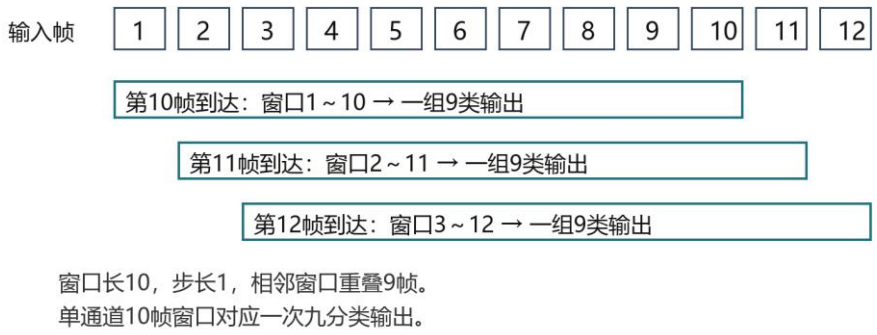


图 3　十帧窗口与步长 1 评价的输出关系

先划分完整 MAT，再在各集合内部生成窗口。原 Train 共 1205 段，在各类别内随机打乱文件，按约 80%与 20%划为 964 段训练集、241 段开发集；每类取整后整体为 80∶20。原 Validation 的 250 段单独作为固定测试集。

表 3　原始集合与项目集合的对应关系

原始来源	项目集合	MAT 数	用途
Train 约 80%	训练集	964	梯度更新、标准化统计、校准候选
Train 约 20%	开发集	241	训练策略比较及最佳检查点选择
Validation 全部	固定测试集	250	冻结候选后的分类评价

同一 MAT 的重叠窗口不跨集合。只有训练集参与梯度更新，开发集不并入最终权重训练，测试集不用于标准化统计或校准选样。固定训练窗步长为 5：20

帧 MAT 产生起点 1、6、11 的 3 窗，50 帧 MAT 产生起点 1、6、11、…、41 的 9 窗，964 段 MAT 文件共 6153 窗。

开发、测试与整段回放评价采用步长 1。T 不少于 10 时，一个 MAT 共有 T−9 个合法窗口，起点为第 1 至第 T−9 帧；开发集共 6836 窗，固定测试集共 7239 窗。窗口不跨 MAT，段切换时清空缓存。每个输出使用连续 10 帧的上下文，相邻评价窗因此重叠 9 帧。

2.3.3 标准化与张量布局

使用训练集全部频谱计算一组全局标量：均值 μ＝137.53303464225368，标准差 σ＝10.262633165907761。每个数值按 z＝(x−μ)/σ 标准化。训练、开发、测试及部署共用该组统计量，不按 512 个频点分别计算，也不逐窗重新估计。每个输入只处理一次；已标准化的文件直接传入运行时。

PyTorch 与 ONNX 采用[1,1,10,512]的 NCHW 布局，Icraft 板端采用[1,10,512,1]的 NHWC 布局，均为 batch1、单通道。网络输入为频谱数值，伪彩瀑布图和 RGB 截图只用于显示。当前集成模型接口不再执行标准化，客户端或数据准备阶段须先完成这一处理。

2.3.4 训练策略与损失函数

先固定 ResNet34、数据划分、30 轮训练预算及每轮样本次数，比较优化器、学习率调度、采样方式和损失权重的组合。固定窗方案每轮遍历同一张 6153 窗位置表，只改变打乱顺序；50 帧 MAT 贡献 9 窗，20 帧 MAT 贡献 3 窗，因而长 MAT 在训练中出现的样本更多。

为平衡类别贡献并消除同类内长短 MAT 的抽样机会差异，采用三级均衡随机采样：先从九类中等概率选一类，再从该类所有参与训练的 MAT 文件中等概率选一份，最后从该 MAT 所有能截取完整 10 帧的起始帧中等概率选一个。T 帧 MAT 有 T−9 个合法起点；20 帧有 11 个，50 帧有 41 个。每轮仍抽取 6153 次，保持更新预算一致，但起点可随训练变化。

普通交叉熵和类别加权交叉熵都是分类损失函数，用于衡量预测与标签的差异并指导参数更新。普通交叉熵对样本等权计算；类别加权交叉熵提高窗口较少

类别的损失贡献。固定窗配置使用类别加权交叉熵，三级均衡随机采样配置使用普通交叉熵。表 4 比较这些因素组成的整体训练策略。

表 4　种子 42 下的 ResNet34 训练策略筛选

训练配置	开发整段准确率	开发整段宏 F1
Adam 固定学习率＋固定窗	92.12%	91.52%
Adam 余弦退火＋固定窗	91.70%	91.28%
AdamW 余弦退火＋固定窗	91.29%	90.80%
AdamW 余弦退火＋三级均衡随机窗	92.95%	92.70%

随机种子控制初始化、抽样及打乱等随机过程。先固定 42 筛选四配置，再仅对基准策略和选中策略补充 43、44，形成两个策略各三个种子的复核。训练策略选择依据为开发集整段宏平均 F1，根据表 4 选择训练配置为 AdamW 余弦退火+三级均衡采样窗。

表 5　基准与选中策略的三种子复核

随机种子	基准策略整段准确率	选中策略整段准确率
42	92.12%	92.95%
43	90.04%	90.87%
44	90.87%	92.95%
均值±样本标准差	91.01%±1.04%	92.25%±1.20%

基准采用 Adam 固定学习率与固定窗，选中策略采用 AdamW 余弦退火与三级均衡随机窗。三种子复核中，选中策略平均整段准确率较高，因此作为后续三模型的共同训练配置；样本标准差用于描述训练波动。

2.3.5 三模型同条件训练与浮点结果

三模型（ResNet18、ResNet34、ResNet50）均把首层改为单通道输入、64 通道输出的 3×3 卷积，时间方向步幅 1、多普勒方向步幅 2，移除入口最大池化，保留短时间维信息。模型随机初始化，不使用 ImageNet 预训练权重。

共同配置为 AdamW 优化器[3]、初始学习率 0.001、权重衰减 0.01、余弦退火最低学习率 0.00001、batch64、30 轮，损失函数为普通交叉熵，采用三级均衡随机采样。均在 RTX5060 8 GB GPU 上训练，使用相同划分、标准化及评价规则；板端 NPU 只执行部署推理。

本阶段固定 42 作为共同参考种子。ResNet34 复用符合该配置的已有权重，ResNet18 和 50 各完成 30 轮训练。每轮评价开发集并按整段宏平均 F1 保存最佳检查点；三者最佳轮次分别为 22、24、24，检查点选择不使用测试标签。

表 6　同条件训练后的 FP32 结果

模型	最佳轮次	开发整段准确率	测试整段准确率
ResNet18	22	92.95%	91.60%
ResNet34	24	92.95%	93.20%
ResNet50	24	87.97%	89.60%

当前 FP32 候选中，ResNet34 的固定测试集表现较好。但部署还取决于量化精度、NPU 时延和内存，因而三者继续接受公共校准输入及板端测试，最终选择见第三部分。

2.4 量化部署与模型接口

2.4.1 代表性校准窗口的选择

量化校准利用输入估计中间数值分布，确定量化范围，不进行梯度训练。候选仅来自 964 段训练 MAT：先列出每份 MAT 的步长 5 起点列表，再取列表约 10%、50%、90%位置，去除短序列的重复位置，得到 2768 个候选窗口。三模型共用最终 54 个输入，各自重新统计激活并计算量化参数。

表 7　用于校准选样的八项频谱统计指标

指标	含义与计算
平均谱值	5120 个数的平均值，表示整体水平。
谱值起伏程度	5120 个数的标准差，表示围绕均值的起伏。
较高谱值的突出程度	95%分位数减中位数，表示较高部分相对中间水平的差距。
最大谱峰的突出程度	最大值减中位数，表示最强谱值的突出程度。
相邻帧变化程度	相同频点相邻帧作差，取绝对值后平均。
相邻频点变化程度	每帧相邻频点作差，取绝对值后平均。
最强峰位置变化	每帧峰值位置的标准差除以 512。
突出频谱的分布宽度	保留高于每帧均值的差值为权重，计算其在−1 至 1 频率轴上的位置标准差。

先将每个候选窗口的八项指标组成一组特征，在各类别内统一数值尺度，并限制极端值的影响，避免某项指标主导距离计算。随后用 K-means 聚为六组：将窗口分配给距离最近的中心，再用组内特征均值更新中心，反复迭代，使频谱特征相近的窗口聚在一起。最后针对六个中心，按距离由近到远选择真实窗口；若所属 MAT 已入选，则顺延选择下一窗口，保证每类六窗来自不同 MAT，九类共 54 窗。聚类只用于校准选样，模型输入仍为按固定 μ/σ 标准化的 10×512 频谱。

2.4.2 导出与量化编译

最佳权重导出为 opset11 ONNX，并在完整开发集核对 PyTorch 与 ONNX。ResNet18 窗口及整段类别一致率均为 100%，最大 logit 绝对差 1.1444×10^{-5}，满足浮点容差；类别一致不表示 FP32 逐位相同。

通过 Icraft 依次完成 parse 图解析、optimize 图优化、quantize 校准量化、adapt 目标适配、generate 模型生成[4]，采用 INT8、逐通道参数及 KL 散度校准，输出配套 JSON 与 RAW。模型内部进行量化计算，外部接口保持 FP32 频谱输入和 9 个 FP32 logits 输出。

2.4.3 输入输出与判决规则

表 8　模型与工程链路共用的调用约定

项目	约定
单次输入	连续 10 帧×512 频点，batch1、单通道
张量布局	PyTorch/ONNX [1,1,10,512]；Icraft [1,10,512,1]
输入字节	小端 FP32，连续存储 20480 字节；固定 μ/σ 标准化一次
模型输出	[1,9]小端 FP32 logits，共 36 字节
类别顺序	0 至 8：UAV1、UAV2、UAV3、UAV4、Bird、Birds、Wing Bird、Rotate、Car
完成条件	PL 完成与 PS 输入核验通过；forward 后等待最终 Tensor 就绪，再读取输出
判决方式	单窗 softmax 取最大项；整段等权平均各窗 softmax，FP64 累计

Icraft 软件开发工具包（Software Development Kit，SDK）提供模型加载、会话建立、前向执行和输出访问接口。程序启动时建立会话，任务间复用已加载模型。每次输入准备完成后执行已验证的 reset(1)、forward 和最终输出等待；普通路径关闭非必要算子回调和重复逐算子等待，按需构造调试信息，同时保留 PL/PS 输入校验及最终输出就绪检查。

单窗判决先对 9 类 logits 计算 softmax，取最大项确定类别，并将其值保存为 summary.score。串口屏的“最高预测概率”即该值乘以 100，保留一位小数。整段判决则在同一 MAT 的全部合法窗口上，按类别等权平均各窗 softmax 概率，再取最大项；计算时用 FP64 累计。整段准确率按每个 MAT 一次判决统计，屏幕概率表示当前窗口的分类分数。

当前上位机每个文件任务只处理一个指定起点的 10 帧窗口。例如，上传 37 帧频谱并设置起点为 0 时，仅推理第 0 至 9 帧。屏幕显示该窗口的结果，并未自动执行该文件全部 28 个合法窗口的整段聚合。

2.4.4 参考输出与运行配置

冻结交付包含 ResNet18_radar_ZG.json 及 RAW、μ/σ、类别映射、固定 27 窗输入与对应 logits、文件散列、Icraft 版本和运行配置。验收先核对文件身份、布局与预处理，再比较原始输出，而不只检查最大类别。输入必须为有限数值，不能跨 MAT 或重复标准化。

运行设置须与参考输出一同冻结。独立三模型比较使用 Icraft 3.36.1、Host 线程 1 和每次推理前 reset(1)，关闭 MergeHardOp 与 ETM；OCM 片上存储优化自动选择 OPTION1。最终整合工程显式采用 OCM＝NONE。更换运行设置后应重新建立匹配参考，数值核对采用相同模型、相同输入及相同运行设置。

2.5 板端调度与通信显示

2.5.1 PC 上位机与 TCP 文件传输

上位机负责板卡连接、文件队列、任务结果和通信日志。板端服务须先启动，PC 再连接其 TCP 端口并读取模型描述。用户添加 BIN 及配套 JSON、设置起始帧和结果目录后提交任务。组合文件每帧包含 512 个已标准化频谱值和 5 个航迹值，客户端拆出频谱上传，航迹与参考类别留在 PC。

组合 BIN 与同名 JSON 共同描述样本。JSON 记录 data_file、帧数、布局、类别、标准化参数、来源及 SHA256，客户端在发送前核对文件身份与内容。更改文件名时同步更新 JSON 文件中的 data_file 字段，保持 BIN 数据、类别标签及来源不变。实际上传的纯频谱每帧 2048 字节，选中的 10 帧窗口为 20480 字节。

PC 先提交任务参数，经上传 READY 批准后发送完整文件。TCP 消息以长度头和正文分帧，板端循环接收后检查长度、CRC、有限数值与窗口边界，再提取连续 10 帧。频谱在数据准备阶段按训练统计量标准化一次，模型运行时直接接收这些数值；航迹与参考标签不进入分类网络。

上位机按任务保存输入来源、模型描述、通信事件、输出及窗口快照，重复发送同一文件会产生新的任务档案。任务表和轨迹详情中的“发送类别”、参考图

片与红框来自配套标注；实际预测记录在模型输出和任务归档中。界面清空仅影响当前列表，磁盘档案和板端历史继续保留。

2.5.2 PS 控制与模型执行

板端常驻 C++服务统一管理任务。Hardware 准备 UDMA 和模型输入缓冲，Bridge 配置并启动 PL；PL 搬运完成且 PS 整窗核验通过后，程序调用 session.forward。等待返回 Tensor 就绪后读取输出，核对地址、数据一致性及数值有效性，再生成 RESULT 消息回传 PC，并发布给 UART 后台线程。控制路径使数据传输完成与计算完成成为两个独立检查条件。

2.5.3 任务结束与异常状态



图 4　上传准入与任务完成之间的状态交接

上传 READY 表示允许发送文件；服务 READY 表示任务已完成、缓冲清理及读回确认通过，可以开始下一任务。收到 STOP 后，程序完成当前任务和清理再退出。硬件异常进入 FAULT 并停止接收新任务；长度、CRC 或数值校验失败时返回错误，按故障类别决定恢复准入或保留现场。

2.5.4 UART 显示与历史查询

UART 后台模块负责串口配置、文本编码、指令应答及断链重连。有效结果和阶段计时按任务标识关联，再写入历史并更新页面。主页 main 显示最近预测、类别编号、最高概率和阶段时间；history 分页列出历史；detail 显示所选记录的任务、窗口起点与处理耗时。触摸事件由板端解析后更新相应控件。

历史查询使用固定快照，返回列表时保留页码，避免新增结果改变当前选中记录。历史持久化在板端，服务重启后可恢复。现行版本在 PC 断开或重新连接时保留上次结果，服务启动后也会读取最后一条历史，并提示“上次成功结果；当前尚无新结果”。

每次发送后，PC 生成独立任务目录；板端将任务事件和 V3_PERF 阶段时间追加至本次服务的 console.log，重新启动服务后建立新的日志目录。串口屏历史保存在 hmi_history.jsonl，同一条记录可因补充任务或清理耗时而追加多行，因此按任务标识和记录编号统计结果数量。

第三部分　完成情况及性能参数

3.1 工程成果与界面

3.1.1 实物连接与硬件工程

系统完成开发板、以太网、串口转换模块和屏幕的桌面连接，形成独立 PL 工程及 PS 控制接口。PL 负责缓存、搬运和读回，PS 将输入核验与 NPU 调用衔接；预测及阶段时间随后回传 PC 并显示在实体屏。图 5 展示硬件组成，图 10 给出可与最终工程日志对应的 ResNet18 单窗结果。

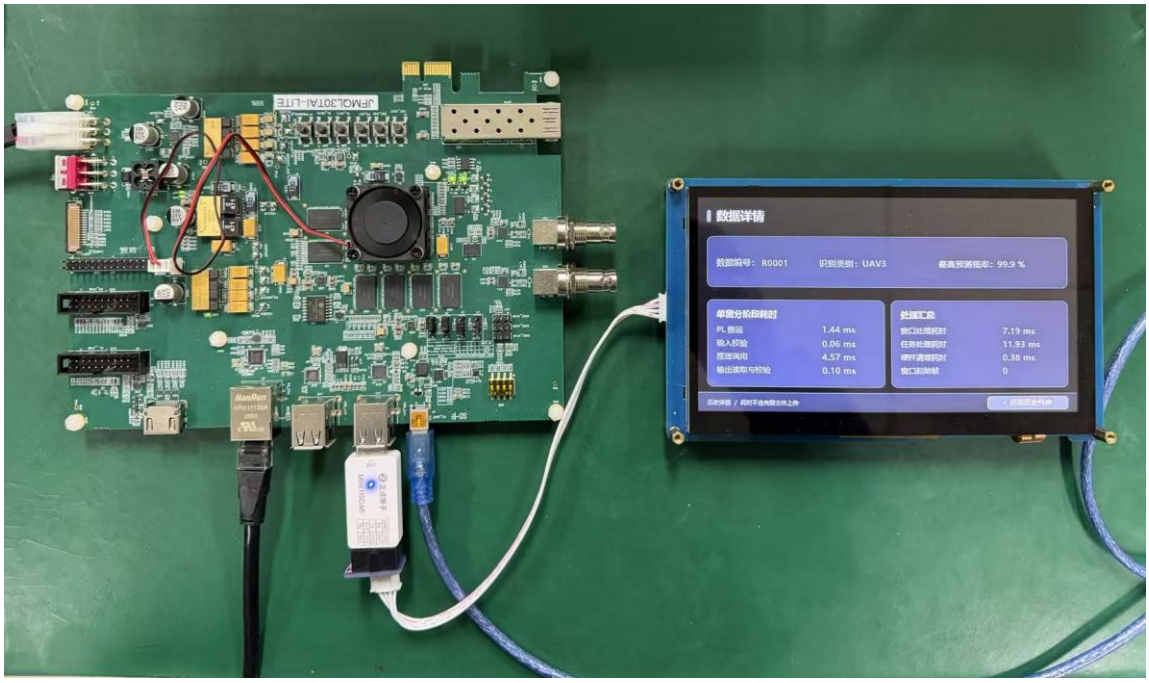


图 5　开发板与串口屏的桌面连接实物

3.1.2 PC 上位机与数据查看

上位机实现连接、文件队列、任务状态、通信日志及归档查看，详情显示所选 10 帧窗口对应的局部轨迹、方向和逐帧运动轨迹。轨迹用于辅助查看运动过程，模型仅使用频谱训练，推理时的数据也仅为频谱数据。另从原 Validation 准备九类各两份共计 18 份演示样例，按预测表现与轨迹可读性选择，用于操作展示；这些精选样例不替代 250 段固定测试集的全量评价。



图 6　PC 上位机文件任务与结果管理界面

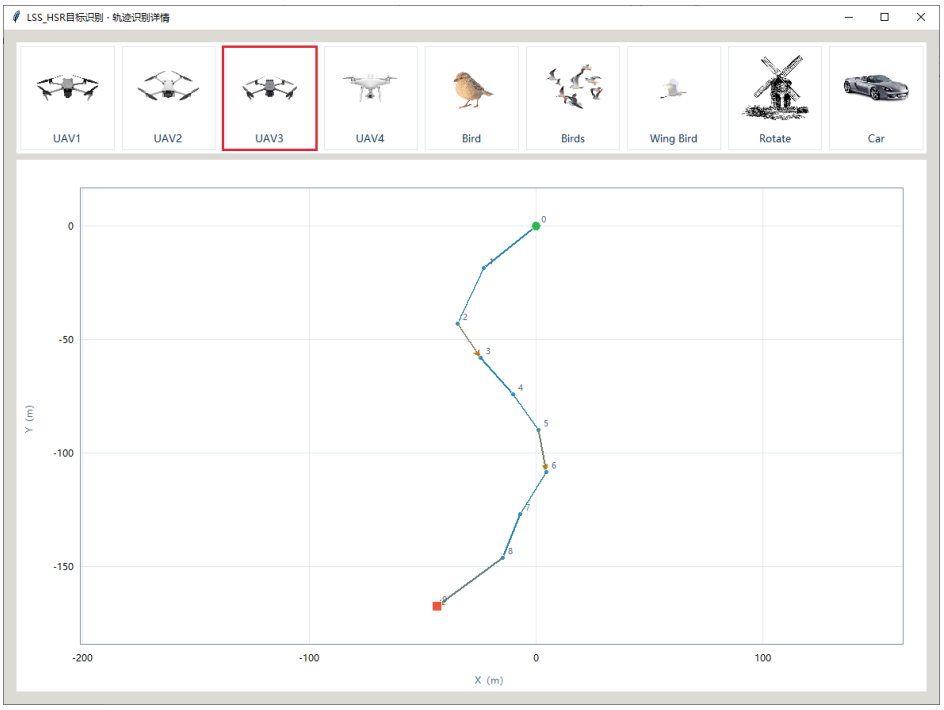


图 7　PC 局部轨迹与类别参考信息界面

3.1.3 串口屏页面与实现状态

串口屏接通最终 ResNet18 工程，实现主页、历史页和详情页的数据组织。图 8、图 9 为页面设计，图 10 为实体屏输出。已核对的调试日志记录了真实串

口连接、窗口结果、任务完成与历史持久化，支持单次预测和阶段耗时展示。历史翻页、选行详情及重连功能由软件实现，完整交互验收仍须结合操作记录。



图 8　串口屏主页设计预览



图 9　串口屏详情页设计预览

图 10 对应最终工程中一项 37 帧输入、起点为 0 的单窗任务，模型为 ResNet18，预测类别 UAV3。原始最高 softmax 分数为 0.9994386，屏幕显示 99.9%；窗口处理 7.1853 ms、任务处理 11.93036 ms 分别显示为 7.19 ms、11.93 ms。图中分数与时间均对应这一次 10 帧窗口处理。



图 10　ResNet18 单窗识别与阶段耗时的实屏显示

3.2 分类精度与最终模型选择

本节为独立模型测试：窗口准确率按每个 10 帧窗口计数，整段准确率按每个 MAT 的一次概率平均判决计数，宏平均 F1 对九个类别等权计算。INT8 Host 在 PC 执行 Icraft 量化模型，板端 INT8 在 ZG330 NPU 执行。该组结果用于模型比较，最终 PS/PL/UART 工程的功能联调另见第 3.5 节。

表 9　固定测试集整段准确率的量化与硬件对照

模型	FP32	INT8 Host	板端 INT8
ResNet18	91.60%	92.00%	92.00%
ResNet34	93.20%	92.00%	92.00%
ResNet50	89.60%	88.00%	88.00%

表 10　板端固定测试集的窗口与整段指标

模型	窗口准确率	整段正确数	整段宏 F1
ResNet18	84.17%	230/250	91.29%
ResNet34	85.21%	230/250	91.41%
ResNet50	79.51%	220/250	87.06%

ResNet18 开发集整段准确率由 FP32 的 92.95%变为 INT8 Host 的 91.70%，固定测试集由 91.60%变为 92.00%，体现了量化对不同样本预测的影响。板端与 Host 的测试整段类别一致率，ResNet18、34、50 分别为 99.20%、99.20%、98.00%。准确率反映与真值的关系，类别一致率反映两种执行方式的关系，二者分别统计。

综合精度和下述资源测试，最终选择 ResNet18。与 ResNet34 相比，固定测试集整段准确率同为 92.00%，SDK 平均请求耗时降低 38.77%，速度提升约 1.63 倍；SDK 管理块由 21.79MiB 降至 11.48 MiB，减少 47.32%，进程 RSS 也降低。该选择接受约 1.04 个百分点的逐窗准确率差。ResNet34 保留为逐窗精度对照，ResNet50 在当前配置下未显示部署优势。

部署的 ResNet18 采用[2,2,2,2]基本残差块配置，经全局平均池化获得 512 维特征，再由全连接层输出 9 类 logits，共 11172297 个参数。其量化精度、时延和内存共同支持本项目的部署选择。

3.3 独立 NPU 推理性能与内存

3.3.1 测试条件与时间定义

三个模型均使用 Icraft 3.36.1、batch1、顺序请求和相同运行设置。测试三轮并轮换模型次序，每模型每轮预热 54 次、计时 1080 次，共 3240 次普通请求，不受 20 ms 回放周期限速。模型及会话已常驻。所有离群值保留。

SDK 请求计时包括输入 Tensor 构造、reset、forward、最终输出等待及 9 类结果读回，不含模型加载、文件读取、标准化、等待收齐 10 帧、PS/PL 外部同步、网络或显示。另用 27 窗单独开启性能剖析，累计 SDK 上报的硬件算子时间。两种测试口径不同，不能精确相减来划分软件开销。

表 11　独立 SDK 请求与硬件算子时间 单位 ms/10 帧窗口

模型	请求均值	请求 P95	请求最大	算子累计均值
ResNet18	3.0841	3.0997	57.4347	1.6886
ResNet34	5.0372	5.0560	56.3761	3.1486
ResNet50	6.3679	6.4020	16.3089	4.6118

P95 表示 95%的已测请求不超过该时间。ResNet18 和 34 各有 1/3240 次超过 20 ms，长尾样本均计入统计，因此均值与 P95 用于描述本次测量，不能作为最坏响应上界。每次请求处理一个完整 10 帧窗口；除以 10 只得到均摊成本。模型在 PC GPU 上训练，本节比较 NPU 部署推理，未开展三模型同条件的 CPU/GPU/NPU 推理速度横向比较。

3.3.2 参数存储与运行内存

进程常驻内存（Resident Set Size，RSS）由操作系统记录，包含 Python、SDK 及模型相关内存；SDK 管理块为 SDK 管理的设备分配快照；权重文件大小为存储占用。三者不能相加，也不能把 SDK 快照当作整个 NPU 物理 DDR 的瞬时峰值。MiB＝1024×1024 字节。内存另行采样，避免采样开销混入测速。

表 12　参数存储与独立进程内存

模型	参数量[百万]	ZG 权重[MiB]	RSS 最大[MiB]	SDK 管理块[MiB]
ResNet18	11.17	11.38	70.88	11.48
ResNet34	21.28	21.64	81.13	21.79
ResNet50	23.52	24.32	85.34	24.50

3.4 输入搬运通路的独立测试

输入搬运基线来自原版 PS/PL 通路的独立实板测试：每窗 10 帧×512 点、小端 FP32，共 20480 字节；预热 54 次后统计 1080 窗，P95 采用最近秩法。该组数

据描述搬运与核验通路。最终工程增加的任务调度、日志与 UART 显示按第 3.5 节的实际联调任务单独说明。

表 13　原版输入通路的独立实板测量

指标	均值	P95	最大值
PL 搬运耗时/ms	1.155	1.159	1.180
PS 整窗核验/ms	0.051	0.052	0.063

PL 搬运计时包含参数配置、写后读回及软件轮询等待，PS 核验包含独立读回与逐字节比较。正式组有效字节数除以累计搬运时间，得到 17.74 MB/s，1 MB＝10^6字节。该速率包含读回和软件开销。搬运、模型计算和任务总时间具有嵌套关系，整机耗时应由同一任务的外层计时测量。

3.5 最终工程联调与实屏结果

最终工程优化 PS 文件校验与缓冲清理开销，并精简 NPU 算子回调和重复等待，同时保留 PL 搬运、输入读回、最终 Tensor 等待及三次输出核对。当前模型 JSON 和 RAW 与冻结 ResNet18 的散列一致。工程记录中可识别出 6 次完成的 ResNet18 单窗调试任务，并有对应 HMI 历史。以下结果用于说明功能接通及显示内容，不作为正式压测。

表 14　最终 ResNet18 工程的联调记录

检查项	记录范围	可确认的结果
模型文件	JSON 与 RAW 散列	当前文件与冻结 ResNet18 一致
任务执行	6 次单窗调试任务	均有 RESULT、DONE 和 CLEANED
历史关联	按任务标识去重	与 6 次任务一一对应
串口连接	日志记录 ttyACM0	具备真实串口连接记录
实屏样例	图 10 对应任务	UAV3、99.9%及阶段耗时一致

图 10 对应运行记录 IfNtZQ 中的首个任务。其 console 日志和 HMI 历史保存了相同模型、窗口起点与阶段时间。该任务上传 37 帧数据，仅对第 0 至 9 帧推理。屏幕“推理调用”取 forward_ms，输出读取与校验取三次输出读回及核对之和，显示值按两位小数取舍。

表 15　图 10 单次任务的日志与屏幕读数

项目	日志值/ms	屏幕值/ms
PL 搬运	1.44433	1.44
PS 输入核验	0.05729	0.06
SDK forward 调用	4.56892	4.57
输出读回与核对	0.10303	0.10
窗口全处理	7.18530	7.19
收完文件后的任务处理	11.93036	11.93
硬件缓冲清理	0.37615	0.38

本例 forward 后的最终等待另为 0.01241 ms，调用与等待合计 4.58133 ms。窗口全处理包含输入准备、PL 搬运、核验、reset、推理和输出读回；任务处理从完整文件接收后开始，另含文件校验、选窗、结果发布和清理。它不含文件正文上传、最后的 READY 往返或实体屏刷新完成。各阶段嵌套计时，清理时间已包含在任务时间内。

这些调试任务的输入文件长度不同，且没有统一预热的正式测速设计，因此不汇总为稳定时延指标，也不据此计算相对旧版本的加速比例。最终整合工程尚无完整 250 段复测和 PC 端到端计时记录；独立模型测试与最终工程单窗联调分别承担模型评价和功能确认。

3.6 结果适用范围与交付状态

已完成仅频谱模型训练、策略比较、代表性校准、量化和三模型独立板端测试，确定 ResNet18；最终工程已接通 PC 上位机、PS/PL/NPU 及实体串口屏。交付包括冻结模型与标准化参数、参考样例、PC 与板端程序、PL 工程、界面资源

和任务日志。92.00%整段准确率来自独立模型评价，实屏结果来自指定窗口，两项结论分别使用。

当前数据为公开频谱文件回放。MAT 级划分避免同一文件的重叠窗口跨集合，但现有元数据不足以证明物理目标或采集会话独立，固定测试集也已被历史工作评价。三架构比较对应当前候选：ResNet34 的种子 42 由历史实验选出，18 和 50 各按固定 42 训练。结论适用于本项目的候选配置与既定数据范围。

最终版本已具有实屏单窗结果，完整交互验收、长时间运行、端到端时延及全量精度复测仍需按同版工程补齐。后续接入连续频谱流时，应把窗口观测等待、排队、传输和屏幕刷新纳入端到端测量。原始 ADC 处理不在当前实现范围内。

第四部分　总结

4.1 可扩展之处

后续保持仅频谱输入，补充独立场景评价，重点改善 UAV3 等易混淆类别，并研究未知类别拒识。工程侧补齐最终版本全量精度、正式测速和完整屏幕交互验收，再优化连续窗口调度与显示刷新。自动清空当前显示可与持久历史分开设计，待实现并验证后纳入系统功能。

另外，从雷达角度而言，后续可以开发射频前端部分，包括采样、雷达目标探测、跟踪等，并输出给当前雷达频谱目标识别微系统，完成从信号采集到目标识别的全链路实现。

4.2 心得体会

模型定义与硬件数据流使用同一套窗口、标准化和类别顺序，是本系统集成的基础。完整文件先划分，再生成窗口，使训练与评价可以复现；网络选型同时考虑量化后精度、请求耗时和内存。当前候选中，ResNet18 与 ResNet34 的整段准确率相同，而前者推理开销更低，因此更适合本项目的板端部署。

工程调试表明，地址绑定、传输完成和输出就绪需要分别确认。普通接收内存与 PL 可访问缓冲分离，PL 写后读回和 PS 整窗比较提供输入有效依据，最终

Tensor 等待保证输出可读取。NPU 路径减少非必要回调及重复等待，PS 路径优化文件校验和擦除开销，同时保留必要的同步、核验和任务清理。

结果解释同样依赖统一定义。整段准确率评价完整目标序列，单窗 softmax 分数解释当前预测；硬件算子、SDK 请求、窗口处理及完整任务具有不同计时边界。通过模型版本、任务标识和原始记录将这些定义落实到每项结果，既能展示已完成的系统，也能明确后续验证和优化应针对的环节。

第五部分　参考文献

[1] 田彪, 陈俊彦, 万延煜, 等. 全息凝视雷达低空目标探测数据集及多特征识别方法[J]. 雷达学报(中英文), 2026, 15(4): 1258-1277. DOI: 10.12000/JR25212.

[2] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]//CVPR. 2016: 770-778. https://arxiv.org/abs/1512.03385.

[3] LOSHCHILOV I, HUTTER F. Decoupled Weight Decay Regularization[C]//ICLR. 2019. https://arxiv.org/abs/1711.05101.

[4] Icraft. Icraft Quantizer 3.36.1.0 Documentation: ZHUGE Quantizer[Z]. Icraft 3.36.1 发行版配套文档.

[5] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[EB/OL]. 2015. https://arxiv.org/abs/1506.02640.